

- ① Primera sumamos los embeddings de "El bongo" y "Agua" para obtener el vector de contexto.

$$\begin{matrix} & D_1 & D_2 & D_3 & D_4 \\ \text{El} & \begin{pmatrix} 0 & 0 & 0 & 1 \end{pmatrix} \\ \text{bongo} & \begin{pmatrix} 1 & 1 & 0 & 0 \end{pmatrix} \\ \text{Agua} & \begin{pmatrix} 1 & 0 & 1 & 0 \end{pmatrix} \end{matrix} + \begin{matrix} & D_1 & D_2 & D_3 & D_4 \\ & \begin{pmatrix} 0 & 0 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 0 & 0 & 0 & 1 \end{pmatrix} \\ & \begin{pmatrix} 0 & 0 & 0 & 2 \end{pmatrix} \end{matrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} = X$$

- 2) Proyecciones ( $q, k, v$ )  $w_q$  y  $w_v$  son la identidad por lo que  $q = X$  y  $v = X$

Calculamos  $k = X \cdot w_k$  obtenemos:  $q =$  Matriz de queries (que busca cada palabra)

$$\begin{matrix} & D_1 & D_2 & D_3 & D_4 \\ \text{El} & \begin{pmatrix} 0 & 0 & 0 & 1 \end{pmatrix} \\ \text{bongo} & \begin{pmatrix} 1 & 1 & 0 & 1 \end{pmatrix} \\ \text{Agua} & \begin{pmatrix} 1 & 0 & 1 & 2 \end{pmatrix} \end{matrix} \cdot \begin{matrix} & D_1 & D_2 & D_3 & D_4 \\ & \begin{pmatrix} 1 & 0 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 0 & 1 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 1 & 1 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 0 & 0 & 0 & 0 \end{pmatrix} \end{matrix} = \begin{matrix} & D_1 & D_2 & D_3 & D_4 \\ & \begin{pmatrix} 0 & 0 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 1 & 1 & 0 & 0 \end{pmatrix} \\ & \begin{pmatrix} 2 & 1 & 0 & 0 \end{pmatrix} \end{matrix} = k$$

$k =$  Matriz de keys (que tanto tengo para ser buscada en cada palabra)

$v =$  Matriz de values (que tanto entrefo si me selecciono para cada palabra)

- 3) Calculamos  $S = q \cdot k^T$  las similitudes

es decir que tenemos compatibles (1) con agua y con cada key. Como tiene es decir como atenderlo da cada token a los demás, se divide por  $\sqrt{n}$  para estabilizar los gradientes

$$n = 4$$

$$\begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix} = S, \text{ sin dividir}$$

- 4) escala

$$S \cdot \frac{1}{\sqrt{n}} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & \frac{3}{2} \\ 0 & \frac{1}{2} & 1 \end{pmatrix}$$

estabiliza la escala de la matriz de atención especialmente para dimensiones grandes

5) Mascarar Ceros: Poner un  $- \infty$  en el triángulo superior derecho de la Matriz de Atribuciones, que impide que se tome más de un turno.

Mascarar =  $\begin{pmatrix} 0 & -\infty & 0 \\ 0 & 1 & -\infty \\ 0 & 1/2 & 1 \end{pmatrix}$  Se usa  $-\infty$  para que los valores sean 0 cuando se aplica Soft Max

6) Aplicamos Soft Max por fila  $\begin{pmatrix} e^x \\ \sum e^x \end{pmatrix}$  convirtiendo los puntos en una distribución de probabilidades que Suma 1

$$\begin{aligned} \text{fila 1} \quad \sum_{i=1}^3 x e^{s_{1i}} &= e^0 + e^{-\infty} + e^{-\infty} = 1 \\ \text{fila 2} \quad \sum_{i=1}^3 x e^{s_{2i}} &= e^0 + e^1 + e^{-\infty} = 3,718 \\ \text{fila 3} \quad \sum_{i=1}^3 x e^{s_{3i}} &= e^0 + e^{0,5} + e^1 = 5,367 \end{aligned}$$

$$A = \begin{pmatrix} \frac{e^0}{1} & \frac{e^{-\infty}}{1} & \frac{e^{-\infty}}{1} \\ \frac{e^0}{3,718} & \frac{e^1}{3,718} & \frac{e^{-\infty}}{3,718} \\ \frac{e^0}{5,367} & \frac{e^{0,5}}{5,367} & \frac{e^1}{5,367} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0,169 & 0,271 & 0 \\ 0,186 & 0,307 & 0,506 \end{pmatrix}$$

Se interpreta como la probabilidad que cada token presta atención a otro

7) Mezcla y Proyección (A.V.W<sub>0</sub>)

$$A.V = \begin{pmatrix} 1 & 0 & 0 \\ 0,269 & 0,371 & 0 \\ 0,186 & 0,307 & 0,506 \end{pmatrix} \cdot \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,271 & 0,271 & 0 & 1 \\ 0,814 & 0,307 & 0,506 & 1,506 \end{pmatrix}$$

Se Agrega la Info Neta de cada token proporcionalmente según la matriz de Atención

$$(A.V)w_0 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,271 & 0,271 & 0 & 1 \\ 0,814 & 0,307 & 0,506 & 1,506 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

La M.W<sub>0</sub> reorganiza la info para combinarla con X.

El Resultado se interpreta como la info contextual para cada token (fila) teniendo en cuenta los otros tokens

8) Residual ( $z = x + AV$ )

$$z = x + AV \cdot w_0 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 4 & 0 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,331 & 0,331 & 0 & 1 \\ 0,814 & 0,302 & 0,506 & 1,506 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,331 & 1,331 & 0 & 2 \\ 1,814 & 0,302 & 1,506 & 3,506 \end{pmatrix}$$

Se enriquecen los embeddings originales con la nueva 3<sup>er</sup> dimensión contextual y se normalizan. Se elimina la necesidad de que Avw<sub>0</sub> represente la 3<sup>er</sup> dim de los embeddings originales.

9) Para ver norm, calculas media y varianza de cada fila y normalizas  $\frac{(x - \mu)}{\sigma}$

$$\mu_1 = \frac{0 + 0 + 0 + 2}{4} = 0,5$$

$$\mu_2 = \frac{1,331 + 1,331 + 0 + 2}{4} = 1,366$$

$$\mu_3 = \frac{1,814 + 0,302 + 1,506 + 3,506}{4} = 1,283$$

$$\sigma_1^2 = \frac{(-0,5)^2 + (-0,5)^2 + (-0,5)^2 + (1,5)^2}{4} = 0,75$$

$$\sigma_2^2 = \frac{0,365^2 + 0,365^2 + (1,366)^2 + (0,634)^2}{4} = 0,634$$

$$\sigma_3^2 = \frac{(0,031)^2 + (-1,428)^2 + (-0,227)^2 + (1,223)^2}{4} = 1,306$$

$$\text{fila 1} \\ \mu_1(z) = \frac{[0, 0, 0, 2] - 0,5}{\sqrt{0,75}} =$$

$$\text{fila 2} = \frac{[1,331, 1,331, 0, 2] - 1,366}{\sqrt{0,634}} =$$

$$\text{fila 3} = \frac{[1,814, 0,302, 1,506, 3,506] - 1,283}{\sqrt{1,306}}$$

normalizados para que la norma sea 1 vector

$$= \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,458 & 0,458 & -1,732 & 0,196 \\ 0,022 & -1,221 & -0,222 & 1,501 \end{pmatrix}$$

$$\frac{[3,102, 0.302, 1.506, 3.506]}{\sqrt{1.652}} - 2.1125 = [0.793, -1.405, -0.422, 1.089]$$

$$L_n(H) \begin{pmatrix} -0.877 & -0.577 & -0.577 & 1.732 \\ 0.458 & 0.058 & -1.715 & 0.796 \\ 0.793 & -1.405 & -0.422 & 1.089 \end{pmatrix}$$

normalizar la fila  
para el 1o y 4to  
elemento

13) Predicción

$$[0.793, -1.405, -0.422, 1.089] \begin{pmatrix} 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} = [0, 0, -0.422, -0.422, 1.586, -2.817]$$

La última fila de la columna total de la A0 se le  
necesita para predecir la prox palabra de  
la fila con la Wout transformada en logits

$$\text{Softmax (logits)} \frac{[e^0, e^0, e^{-0.422}, -0.422, 1.586, -2.817]}{8.192} = [0.122, 0.122, 0.026, 0.026, 0.596, 0.004]$$

Pelo

Usamos Softmax para transformar los logits a  
probabilidades. La predicción final es "Pelo" con  
59,6%

1) Fase 2 "El banco presta"

1) Entrada

$$X = E + P \quad \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

2) Proyección

$$q = X \cdot w_q = X$$

$$v = X \cdot w_v = X$$

$$K = K \cdot w_k = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{pmatrix}$$

3) Actividad

$$S = q \cdot K^T \quad \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

$$4) \frac{S}{\sqrt{S}} = \frac{S}{2} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix}$$

5) Matriz Correlación

$$S = \begin{pmatrix} 0 & -0.000 \\ 0 & 1.000 \\ 0 & 1/5 & 1 \end{pmatrix}$$

7) Matriz

6) Matriz Atención

$$\begin{pmatrix} 1 & 0 & 0 \\ 0.269 & 0.771 & 0 \\ 0.186 & 0.302 & 0.306 \end{pmatrix}$$

$$Av. w_0 = \begin{pmatrix} 1 & 0 & 0 \\ 0.269 & 0.771 & 0 \\ 0.186 & 0.302 & 0.306 \end{pmatrix} \cdot \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0.771 & 0.771 & 0 & 1 \\ 0.302 & 0.819 & 0.506 & 1.506 \end{pmatrix}$$

# 8 Residual

$$z = x + Avw_0 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,814 & 0,506 & 1,506 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 1,814 & 1,506 & 3,506 \end{pmatrix}$$

# 9 Layer norm

$$L_1(z) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,458 & 0,458 & -1,215 & 0,796 \\ -1,291 & 0,027 & -0,242 & 1,508 \end{pmatrix}$$

# 10) feed forward $FF_N = \text{ReLU}(L_1(z)w_1)w_2$

$$\text{ReLU} \left[ \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,458 & 0,458 & -1,215 & 0,796 \\ -1,291 & 0,027 & -0,242 & 1,508 \end{pmatrix} \cdot \begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \right]$$

$$\text{ReLU} \left[ \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1,34 & 1,31 & 0 & 0 \end{pmatrix} \right] = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,31 & 0 & 0 \end{pmatrix}$$

# 11 Residual

$$H = z + FF_N = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 1,814 & 1,506 & 3,506 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,31 & 0 & 0 \end{pmatrix}$$

# 12) Layer norm

$$L_2(H) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,458 & 0,458 & -1,215 & 0,796 \\ -1,403 & 0,293 & -0,422 & 1,084 \end{pmatrix}$$

### 13 Prediction

$$\text{Logits} = [-1.405, 0.797, -0.922, 1.089] \cdot \begin{pmatrix} 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

$$= [0, 0, -0.472, -0.472, -2.81, 1.586]$$

$$\text{Softmax}(\text{Logits}) = [0.122, 0.122, 0.026, 0.026, 0.007, 0.596]$$

Predict "Dixie" (0.596% Prob)

## PARTE B

"El banco equitativo"

matriz de afinidades escaladas  $\left(\frac{S}{\sqrt{a}}\right)$ :

$$S = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix} \quad \text{esta matriz contiene las afinidades escaladas entre variables}$$

a) matriz de jerarquía  $(A = \text{softmax}\left(\frac{S}{\sqrt{a}}\right))$

• Primera fila:  $e^0 + e^0 + e^0 = 3 \quad \left(\frac{e^0}{3}, \frac{e^0}{3}, \frac{e^0}{3}\right) = (0.3333, 0.3333, 0.3333)$

• Segunda fila:  $e^0 + e^1 + e^{1.5} = 3.2 \quad \left(\frac{e^0}{3.2}, \frac{e^1}{3.2}, \frac{e^{1.5}}{3.2}\right) = (0.122, 0.337, 0.541)$

• Tercera fila:  $e^0 + e^{0.5} + e^1 = 5.367 \quad \left(\frac{e^0}{5.367}, \frac{e^{0.5}}{5.367}, \frac{e^1}{5.367}\right) = (0.186, 0.307, 0.506)$

$$A = \begin{pmatrix} 0.333 & 0.333 & 0.333 \\ 0.122 & 0.337 & 0.541 \\ 0.186 & 0.307 & 0.506 \end{pmatrix} \rightarrow \text{"Banco" toma 51,7\% de la infra. contextual de "equitativo"}$$

7) Regula

$$(AV)W_0 = AV \begin{pmatrix} 0.333 & 0.333 & 0.333 \\ 0.122 & 0.337 & 0.541 \\ 0.186 & 0.307 & 0.506 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0.1 \\ 1 & 1 & 0.1 \\ 1 & 0 & 1.2 \end{pmatrix} = \begin{pmatrix} 0.667 & 0.333 & 0.333 & 1.333 \\ 0.812 & 0.337 & 0.541 & 1.542 \\ 0.814 & 0.307 & 0.506 & 1.506 \end{pmatrix}$$

8) Residual

$$\tilde{z} = x + (AV)W_0 \quad \tilde{z} = x + (AV)W_0$$

$$\tilde{z} = \begin{pmatrix} 0 & 0 & 0.1 \\ 1 & 1 & 0.1 \\ 1 & 0 & 1.2 \end{pmatrix} + \begin{pmatrix} 0.667 & 0.333 & 0.333 & 1.333 \\ 0.812 & 0.337 & 0.541 & 1.542 \\ 0.814 & 0.307 & 0.506 & 1.506 \end{pmatrix} = \begin{pmatrix} 0.667 & 0.333 & 0.333 & 2.333 \\ 1.812 & 1.337 & 0.647 & 2.542 \\ 1.814 & 0.307 & 1.506 & 2.306 \end{pmatrix}$$

9) Eigen norm

$$\mu_1 = 0.917 \quad \sigma_1^2 = 0.683$$

$$\mu_2 = 0.1576 \quad \sigma_2^2 = 0.538$$

$$\mu_3 = 0.1783 \quad \sigma_3^2 = 1.306$$

$$L_n(z) = \begin{pmatrix} -0,302 & -0,204 & -0,104 & 1,208 \\ 0,412 & -0,333 & -1,403 & 1,323 \\ 0,026 & -1,292 & -0,242 & 1,508 \end{pmatrix}$$

La fila de banco es  $(0,412; -0,333; -1,403; 1,323)$

Reges norm normaliza cada fila

"El banco presta..."

$$S = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,5 \\ 0 & 0,5 & 1 \end{pmatrix}$$

Matriz de atención

$$A = \begin{pmatrix} 0,333 & 0,333 & 0,333 \\ 0,122 & 0,331 & 0,547 \\ 0,136 & 0,302 & 0,506 \end{pmatrix}$$

Regla

$$(AV)w_0 = \begin{pmatrix} 0,333 & 0,333 & 0,333 \\ 0,122 & 0,331 & 0,547 \\ 0,136 & 0,302 & 0,506 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1,2 \end{pmatrix} = \begin{pmatrix} 0,333 & 0,666 & 0,333 & 1,333 \\ 0,331 & 0,818 & 0,547 & 2,517 \\ 0,302 & 0,314 & 0,506 & 1,506 \end{pmatrix}$$

Residual

$$z = x + (AV)w_0$$

$$z = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0,333 & 0,666 & 0,333 & 1,333 \\ 0,331 & 0,818 & 0,547 & 2,517 \\ 0,302 & 0,314 & 0,506 & 1,506 \end{pmatrix} = \begin{pmatrix} 0,333 & 0,666 & 0,333 & 2,333 \\ 1,331 & 1,818 & 0,547 & 2,517 \\ 0,302 & 1,814 & 1,506 & 3,306 \end{pmatrix}$$

Reges norm

$$L_n(z) = \begin{pmatrix} -0,703 & 0,302 & -0,903 & 1,708 \\ -0,334 & 0,412 & -1,403 & 1,324 \\ -1,292 & 0,027 & -0,242 & 1,508 \end{pmatrix}$$

valores de banco =  $(-0,334, 0,412, -1,403, 1,324)$

## Preguntas:

- 1) El vector de "hombre" cambia en la parte B ya que tiene información sobre la palabra que sigue (siguiente / presta). En la parte A el vector es igual porque la máquina no le permite ver la palabra siguiente.
- 2) El modelo usa la representación de la última palabra, no solo "hombre". Si la última palabra es "siguiente", podría ser "pero", "ni", "presta", podría decir.
- 3) La predicción final es igual porque la última palabra ya puede mirar todas las palabras anteriores con la misma casual. El sacarlo no consigue información que no se tenía porque después de ella no hay ninguna más palabra.
- 4) La parte A se parece a un decoder-only, como GPT que se basa en predecir la siguiente palabra. La parte B, se parece a un encoder, como BERT, que puede mirar toda la frase y se usa para comprender y clasificar textos.
- 5) ~~ambos se parecen, en el embedding de~~ posición. En el embedding de posición la frase "el hombre siguiente" sería lo mismo que "hombre siguiente el", pero todas las dificultades para distinguir su orden. "el perro muerde al hombre" y "el hombre muerde al perro" tienen mismas palabras pero el orden cambia completamente el significado.